

AOIRiskGate

影像分類風險閘門與人工複核決策流程

From classification to risk-aware decision flow

Yvan

經歷：

精金科技 | 薄膜製程工程師 (2021–2025)

- 具備製程現場的**問題拆解**、**數據分析**與**改善經驗**，習慣先定義**目標限制**、**風險與成本**，再設計解法。
- 目前正將這套工程思維投入到 AI / ML / CV領域，把模型輸出轉成可支援決策的系統

學歷：

- 資展國際 | Python AI 應用工程師就業養成班 (2025)
- 成功大學 | 材料科學及工程學系 碩士 (2016–2019)
- 長庚大學 | 化工與材料工程學系 學士 (2012–2016)

About this Project

- 在**影像分類**任務中，如何使模型輸出持續具備決策可靠性，並在**高自動化**條件下有效**權衡漏檢風險**與**人工複核成本**。

■ 缺陷影像分類關鍵挑戰：

高信心 ≠ 可直接放行

- 若錯誤樣本被直接放行，仍會形成漏檢與品質風險

若模型輸出沒有風險排序，人工複核就無法有效配置

- 未能進行完整風險評估，放貨靠運氣...
- 無法應付新製程波動、新型變異應變能力弱

✓ 真正要解的是：


哪些樣本可以自動放行？

哪些樣本應該送人工複核？

在固定 review budget 下，escape risk 有多大？

若只能先看一小部分，哪些樣本最該優先看？

- 目標：利用模型輸出，來協助現場做風險控管與資源分配



Core Method: Embedding-Based Risk Scoring

05 / 11

不只問模型『分成哪一類』，也問它『像不像這一類的正常樣子』。

Step 1 | Extract embedding

擷取分類頭前的 **embedding**，保留比最終分類結果更完整的特徵資訊。

Step 2 | Build PCA subspace by predicted class

依 predicted class 建立 **PCA** 子空間，用預測正確樣本描述該類別的正常特徵分佈。

Step 3 | Convert deviation into risk score


以 **重建誤差** 衡量偏離程度，再經**各類別標準化**轉成可跨類別比較的 **risk score**。

➤ **risk score** 越大，代表樣本**越偏離**該預測類別的正常特徵分佈，因此**越值得送人工複核**。


實驗條件

- Model select: **Pretrained ResNet18** (freeze backbone)
- Dataset: **NEU-DET** (鋼板表面缺陷共6類, 1800張影像)
- 加入Random Horizontal / Vertical Flip, Rotation
- Batch_size: 128, epochs: 20

驗證結果



Baseline model performance on NEU-DET validation



Validation Accuracy

92.78%


Macro F1

92.47%

- ✓ 這個 baseline 的目的不是追求極限 accuracy，而是先建立可用的分類能力，進一步驗證 risk gate 是否能有效攔截高風險錯判。

Per-class Risk Score Distribution

07 / 11




✓ Per-class |z-score| distribution after normalization; threshold can be aligned to operational review policy.

Note:

- 不同預測類別的 raw reconstruction error 尺度不同。若直接使用 global threshold，會對某些類別過嚴、對某些類別過鬆。
- 因此需要對各預測類別做正規化，讓 threshold 變成跨類別可比較、可對應實際人工複核策略的門檻。

Tradeoff Curve: Review Rate vs. Escape Rate

08 / 11



Error capture rate

69.23%

At 5% Review

Escape Rate

2.33%

After 5% review

Min review for 0 escape


7.22%

On this validation set


Note:

- 在保留 95% 自動化率下，系統可攔下 18 / 26 個錯判，將 escape rate 降至 2.34%。
- 若把 review rate 提高至 7.22%，則可在此驗證集上攔下全部錯判。


➤ Threshold 不只是模型參數，而是可直接轉譯成 review policy 的決策槓桿。




Inclusion




Pitted Surface




scratches



Inclusion → Pitted Surface



Pitted Surface → Inclusion



Inclusion → Scratches

- Inclusion → Pitted Surface : 12 ea
- Inclusion → Scratches : 8 ea
- Pitted Surface → Inclusion : 4 ea

- 目前模型會因**特徵重疊**而在**爭議性**樣本上產生誤差。
- 利用**重建誤差**產出的 Risk Score 來標定這些樣本的『**偏離程度**』。能把原本會被**誤判**的樣本，轉化為可供工程師複檢的**資訊**，或用來定義下一輪**資料補強**與**模型優化**方向。

1. 切出獨立測試集或合成資料，驗證資料發生飄移時，是否可保持攔截能力。
2. 若**資料分佈**改變，既有 threshold 不一定可直接沿用，因此後續應加入**飄移監控**、**重標注**或**再校正**流程。
3. 後續可整合純分類、人工標註、模型微調與增量續訓等模組，增強迭代能力。

Project value: 讓模型輸出更接近可用的決策資訊

- **量化風險**：結合 **Embedding** 特徵與**重建誤差**，將分類模型延伸為具指標性的**風險評分**（Risk Score），作為**優先覆核順序**的量化依據。
- **策略對接**：透過**閾值校正**（Threshold Calibration）將模型輸出轉化為可執行的人工**複核策略**，藉此實現**人力資源與風險成本**的權衡。
- **反饋閉環**：誤判樣本不僅用於誤差分析，更作為後續**監測預警**、**數據增強與模型迭代**的核心驅動力。

核心技術與實作流程

- 針對**專案風險與成本**進行可行性評估，並據此設計分析路徑。
- 整合**電腦視覺與機器學習**技術，建構包含**訓練、校正至自動化報表**的完整原型。
- 將**業務需求**轉化為**量化指標**，建立具備**可重現性與可驗證性**的分析工作流。

Thank you
